Laporan Tugas GSLC

HASAN — 2802529203

Bagian A

A1. Efek Regularisasi pada Batch Normalization

Efek regularisasi pada BatchNorm (BN) terjadi karena mean dan varians dihitung per mini-batch, bukan dari keseluruhan data (Slide 6–8; Ioffe & Szegedy, 2015). Karena isi batch (misalnya 32 gambar) selalu berganti, statistiknya ikut bergeser sedikit. Artinya, satu gambar yang sama dinormalisasi sedikit berbeda tergantung siapa "teman" di dalam batch-nya. Variasi kecil ini bertindak seperti noise yang mencegah model menghafal data. Itulah kenapa Slide 8 menyebut BN "acts like mild regularization" dan sering membuat Dropout tidak diperlukan. Namun, asumsi ini tidak berlaku pada tiga kondisi:

- **Batch size terlalu kecil (1–4 gambar):** mean dan varians jadi ngawur, sehingga training tidak stabil. Running statistics yang dipakai saat inference juga jadi tidak akurat.
- **Dataset sedikit tapi model besar:** efek BN yang hanya "ringan" tidak cukup menahan overfitting tanpa Dropout.
- **Dropout ditaruh sebelum BN:** running mean/varians dicatat saat Dropout aktif, padahal saat inference Dropout dimatikan. Statistiknya jadi tidak cocok sehingga output model bergeser (Li et al., 2019).

A2. Degradasi Jaringan Dalam dan Formulasi Residual

Penambahan lapisan pada plain CNN sering memicu masalah degradasi, di mana akurasi training justru memburuk. Masalah utamanya bukan overfitting, melainkan model yang semakin sulit dilatih (Slide 10). Secara teori, lapisan tambahan bisa saja sekadar meneruskan input apa adanya (identity mapping). Namun pada praktiknya, lapisan non-linear biasa kesulitan mempelajari fungsi identitas ini, sehingga informasi justru terdistorsi.

Solusinya adalah skip connection (Slide 11–12; He et al., 2016) dengan formulasi $y = F(x) + x$. Jika suatu lapisan tidak diperlukan, model cukup menekan $F(x)$ mendekati nol, dan input asli x akan lewat begitu saja. Saat backpropagation, gradiennya menjadi $\partial L/\partial x = \partial L/\partial y \cdot (\partial F/\partial x + 1)$. Angka +1 dari jalur x ini menjadi semacam "jalan tol": gradien bisa mengalir langsung ke lapisan-lapisan awal tanpa terus-menerus dikalikan turunan lapisan yang kecil. Mekanisme ini memitigasi vanishing gradient (materi Sesi 02), sehingga gradien tidak menyusut dan hilang pada jaringan yang sangat dalam.

A3. Feature Extraction vs Fine-Tuning

Dimensi	Feature Extraction	Fine-Tuning
Parameter yang diperbarui	Sangat sedikit, hanya head baru (di eksperimen ini: 5.130)	Banyak, sebagian atau seluruh backbone (layer4 + fc: 8.398.858)
Volume data latih	Sedikit data sudah memadai	Membutuhkan data lebih banyak
Beban komputasi dan memori per epoch	Jauh lebih ringan dan cepat; gradien hanya disimpan untuk head	Lebih berat karena backpropagation harus mencapai lapisan dalam dan menyimpan gradiennya
Risiko destructive updates	Hampir nol, karena backbone dibekukan	Fitur bawaan bisa rusak, terutama jika learning rate terlalu besar

Kriteria praktis (Slide 15, 16, 29): Feature extraction dipilih jika dataset target sedikit tetapi karakteristiknya mirip dataset asal seperti ImageNet. Ini cara paling aman dan efisien. Fine-tuning dipilih jika dataset cukup besar atau karakteristiknya berbeda jauh dari dataset asal. Praktik terbaiknya adalah tidak langsung fine-tuning. Mulai dengan feature extraction untuk menstabilkan head baru, lalu buka lapisan dalam secara bertahap dengan learning rate jauh lebih kecil, agar fitur bawaan beradaptasi tanpa rusak.

A4. Kaidah Penerapan Data Augmentation

Augmentasi hanya pada train set. Data augmentation mensimulasikan variasi data tambahan untuk meningkatkan generalisasi model (Slide 20). Pipeline ini hanya diaktifkan pada train set, karena fase pelatihan adalah "latihan" agar model kebal terhadap variasi. Sebaliknya, validation dan test set berfungsi sebagai "ujian", sehingga harus memakai citra asli yang selalu sama. Jika data evaluasi ikut diacak, metriknya akan berfluktuasi, keputusan early stopping berdasarkan val loss jadi tidak bisa diandalkan, dan hasilnya gagal mencerminkan performa nyata (Shorten & Khoshgoftaar, 2019).

Transformasi yang tidak layak. Pergeseran hue secara acak (Slide 21) tidak layak untuk klasifikasi ras hewan karena melanggar invariansi semantik label. Warna dan pola bulu adalah ciri utama pembeda ras, misalnya pola colorpoint pada Siamese dan Birman. Jika warna bulu berubah menjadi ungu atau hijau, ciri tersebut hilang dan labelnya tidak lagi valid. Berbeda dengan perubahan brightness/contrast ringan yang dipakai di eksperimen ini, yang hanya mensimulasikan perbedaan pencahayaan.

A5. Mitigasi Catastrophic Forgetting

Mekanisme hilangnya representasi bawaan (Slide 28). Catastrophic forgetting terjadi ketika fine-tuning berlangsung terlalu agresif. Head baru yang diinisialisasi acak menghasilkan error dan gradien yang sangat besar di awal training. Jika backbone ikut dilatih bersamaan dengan learning rate (LR) tinggi, gradien besar ini akan "menimpa" bobot lama yang sudah bagus, sehingga fitur visual umum hasil belajar dari ImageNet hilang (Kirkpatrick et al., 2017). **Dua strategi mitigasi (Slide 16, 29):**

- **Gradual unfreezing:** backbone dikunci di awal dan hanya head yang dilatih sampai stabil, lalu lapisan dalam dibuka secara bertahap. Strategi ini efektif karena gradien besar dari head acak tidak sempat merusak bobot pra-latih (Howard & Ruder, 2018).
- **Differential learning rate:** bagian model yang berbeda diberi LR berbeda, seperti pada eksperimen B3 (fc 1e-3, layer4 1e-4). Backbone sudah berisi fitur umum yang tetap berguna, jadi cukup digeser sedikit agar ilmu bawaannya terjaga. Sementara itu, head baru tetap belajar cepat.

Bagian C — Laporan dan Analisis

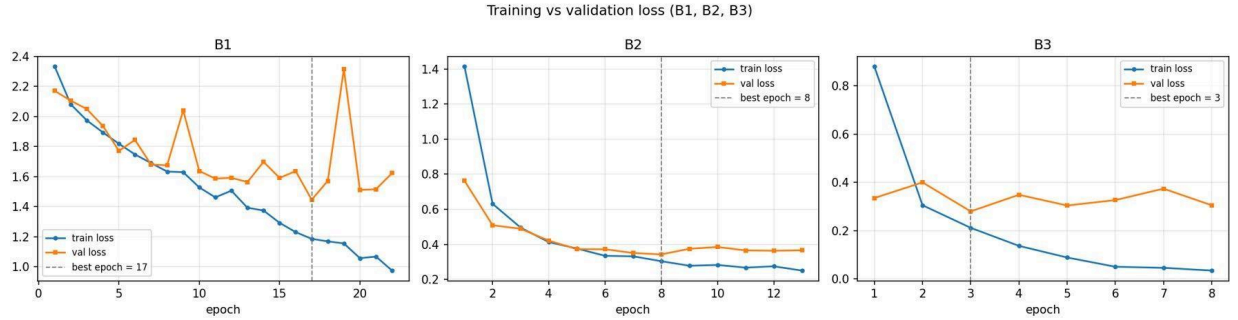
Setup eksperimen. Dataset Oxford-IIIT Pet, 10 kelas (Abyssinian, Bengal, Birman, Ragdoll, Siamese, American Pit Bull Terrier, Staffordshire Bull Terrier, Beagle, Basset Hound, Samoyed), dibagi stratified 70/15/15: train 1.390, val 298, test 298. Semua model memakai input 224×224 dengan normalisasi ImageNet, batch 32, AdamW (weight decay 0,01), CrossEntropyLoss, dan early stopping pada val loss (patience 5, maksimal 30 epoch), dengan seed 42. Augmentasi (RandomResizedCrop, horizontal flip, rotasi 15°, color jitter brightness/contrast) hanya diterapkan pada train set. Eksperimen dijalankan di Google Colab (Tesla T4).

C1. Tabel Konsolidasi dan Kurva Pembelajaran

Tabel 1 merangkum seluruh eksperimen; semua angka diambil dari summary.csv. Train acc dan val acc dicatat pada epoch terbaik (val loss terendah). B4 dengan augmentasi identik dengan B3.

Tabel 1. Ringkasan hasil eksperimen B1–B5

Kode	Strategi	Trainable params	Learning rate	Epoch terbaik / total	Waktu (s)	Train acc	Val acc	Test acc	Test Macro F1
B1	ResNet-18 from scratch	11.181.642	all 1e-3	17 / 22	316,0	0,557	0,487	0,440	0,416
B2	ResNet-18 feature extraction	5.130	fc 1e-3	8 / 13	180,3	0,904	0,869	0,873	0,871
B3	ResNet-18 fine-tune layer4 + fc	8.398.858	layer4 1e-4, fc 1e-3	3 / 8	109,0	0,930	0,883	0,916	0,915
B4	B3 tanpa augmentasi	8.398.858	layer4 1e-4, fc 1e-3	5 / 10	95,5	1,000	0,893	0,923	0,921
B5	EfficientNet-B0 fine-tune	1.142.202	features[7:] 1e-4, head 1e-3	6 / 11	170,1	0,945	0,920	0,930	0,929
B5	MobileNetV3-Small fine-tune	1.337.586	features[9:] 1e-4, head 1e-3	5 / 10	143,1	0,934	0,866	0,896	0,896



Gambar 1. Kurva training loss vs validation loss untuk B1, B2, dan B3

C2.1 Disparitas Performa B1 vs B2 dan B3

Disparitas tajam ini terjadi karena B1 mengalami underfitting akibat kekurangan data, sementara B2 dan B3 tertolong oleh representasi fitur pra-latih. B1 hanya mencapai F1 0,416 dengan akurasi latih 0,557. Rendahnya akurasi latih menunjukkan model belum mampu mempelajari pola bahkan pada data latih, sedangkan gap train-val yang kecil (0,070) menegaskan bahwa masalahnya bukan overfitting. Validation loss B1 juga tidak stabil dan sempat melonjak ke 2,317 (Gambar 1). Karena ResNet-18 sudah memiliki residual connection (Slide 10–12), masalah ini bukan disebabkan kedalaman jaringan, melainkan 1.390 citra terlalu sedikit untuk melatih 11 juta parameter dari nol (Slide 15).

Sebaliknya, B2 (F1 0,871) dan B3 (F1 0,915) memanfaatkan bobot ImageNet yang sudah mampu mengekstraksi fitur visual dasar seperti tepi, tekstur, dan bentuk (Slide 14). Model tidak perlu belajar dari awal, cukup menyesuaikan fitur yang sudah matang ke domain target, sehingga performanya jauh lebih baik dan stabil (Yosinski et al., 2014).

C2.2 Feature Extraction (B2) vs Fine-Tuning Bertahap (B3)

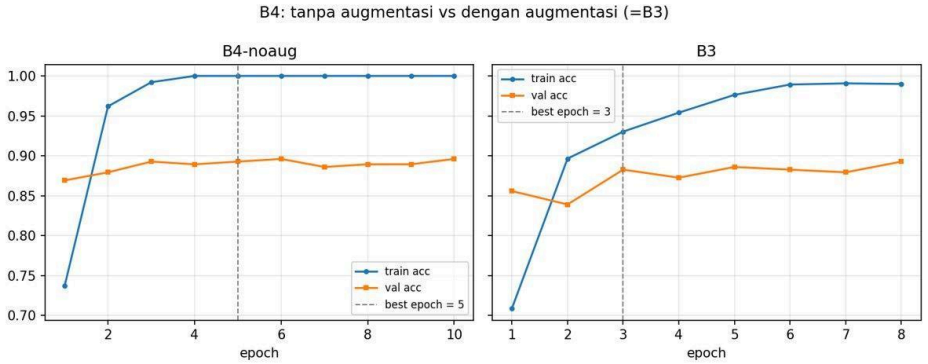
Terdapat trade-off jelas antara stabilitas dan kemampuan adaptasi pada volume data yang terbatas. Pada feature extraction murni (B2), stabilitas sangat tinggi karena backbone dibekukan dan model hanya melatih classifier head, sehingga gap train-val paling rapat (0,035). Namun performanya mentok di F1 0,871. Val acc B2 sudah tertahan di sekitar 0,87 sejak epoch 5, karena fitur yang dibekukan tidak mampu mempelajari ciri halus (fine-grained features) yang membedakan antar-ras.

Sebaliknya, fine-tuning parsial (B3) membuka layer4 untuk dilatih ulang (8,4 juta parameter aktif). Strategi ini lebih adaptif, terbukti dari F1 yang naik menjadi 0,915. Harganya adalah stabilitas: kapasitas yang besar pada data terbatas membuat model cepat menghafal (Slide 28). Val loss terbaik sudah tercapai di epoch 3 (gap 0,048). Setelah itu, train acc terus naik hingga 0,99 sementara val acc tertahan di sekitar 0,88. Early stopping mengembalikan bobot epoch 3, sehingga risiko ini terkendali. Dengan differential learning rate dan early stopping (Slide 16, 29), B3 memberi performa terbaik di antara konfigurasi ResNet-18.

C2.3 Peran Augmentasi (B4)

Augmentasi terbukti efektif meredam overfitting, meskipun tidak menaikkan akurasi secara signifikan. Tanpa augmentasi, model menghafal data latih. Akurasi latih sudah mencapai 1,000 pada epoch 4, sementara akurasi validasi tertahan di sekitar 0,89, sehingga gap train-val mencapai 0,107 (Gambar 2). Dengan augmentasi (B3), gap tersebut turun menjadi 0,048, kurang dari setengahnya. Hal ini terjadi karena citra latih selalu sedikit berbeda di setiap epoch (dibalik, diputar, diubah kecerahannya), sehingga model tidak bisa menghafal dan dipaksa mempelajari ciri yang lebih umum (Slide 20).

Di sisi lain, F1 test tanpa augmentasi (0,921) sedikit lebih tinggi daripada dengan augmentasi (0,915). Namun selisih 0,006 ini hanya setara sekitar 2 citra dari 298, dan eksperimen hanya memakai satu seed. Selisih tersebut belum cukup untuk menyimpulkan mana yang lebih akurat. Yang terlihat jelas dari data adalah peran augmentasi dalam menekan overfitting.



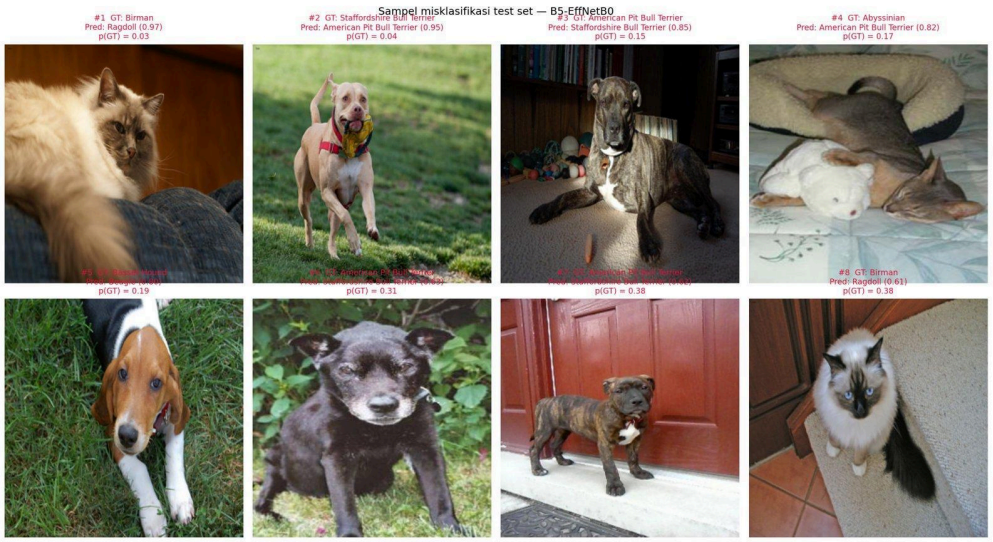
Gambar 2. Akurasi train dan validasi: B4 tanpa augmentasi (kiri) vs dengan augmentasi/B3 (kanan)

C3. Failure Analysis

Model terbaik berdasarkan val accuracy adalah EfficientNet-B0 (B5), dengan 21 kesalahan dari 298 citra test. Tabel 2 dan Gambar 3 memuat 8 kesalahan dengan confidence tertinggi.

Tabel 2. Delapan sampel misklasifikasi dan hipotesis penyebabnya

No	Label aktual	Prediksi (confidence)	Hipotesis penyebab
1	Birman	Ragdoll (0,97)	Kaki putih ("sarung tangan") khas Birman tidak terlihat karena kucing berbaring dan menoleh, padahal itu ciri utama pembeda dengan Ragdoll.
2	Staffordshire Bull Terrier	American Pit Bull Terrier (0,95)	Ambiguitas antar-ras: kedua ras ini hampir identik secara visual.
3	American Pit Bull Terrier	Staffordshire Bull Terrier (0,85)	Ambiguitas antar-ras: bentuk kepala dan otot kedua ras sangat mirip.
4	Abyssinian	American Pit Bull Terrier (0,82)	Pose ekstrem: kucing telentang dengan wajah miring, sehingga bentuk tubuh khas kucing tidak terbaca.
5	Basset Hound	Beagle (0,80)	Ciri pembeda Basset (kaki pendek, badan panjang) tidak terlihat karena anjing berbaring dan foto fokus ke wajah.
6	American Pit Bull Terrier	Staffordshire Bull Terrier (0,63)	Usia tua mengubah penampilan (moncong beruban), sehingga berbeda dari mayoritas contoh di data latih.
7	American Pit Bull Terrier	Staffordshire Bull Terrier (0,62)	Masih anak anjing, sehingga proporsi tubuhnya belum seperti anjing dewasa.
8	Birman	Ragdoll (0,61)	Ambiguitas antar-ras: warna colorpoint, mata biru, dan bulu panjang sangat mirip.



Gambar 3. Delapan sampel test yang salah diprediksi oleh EfficientNet-B0

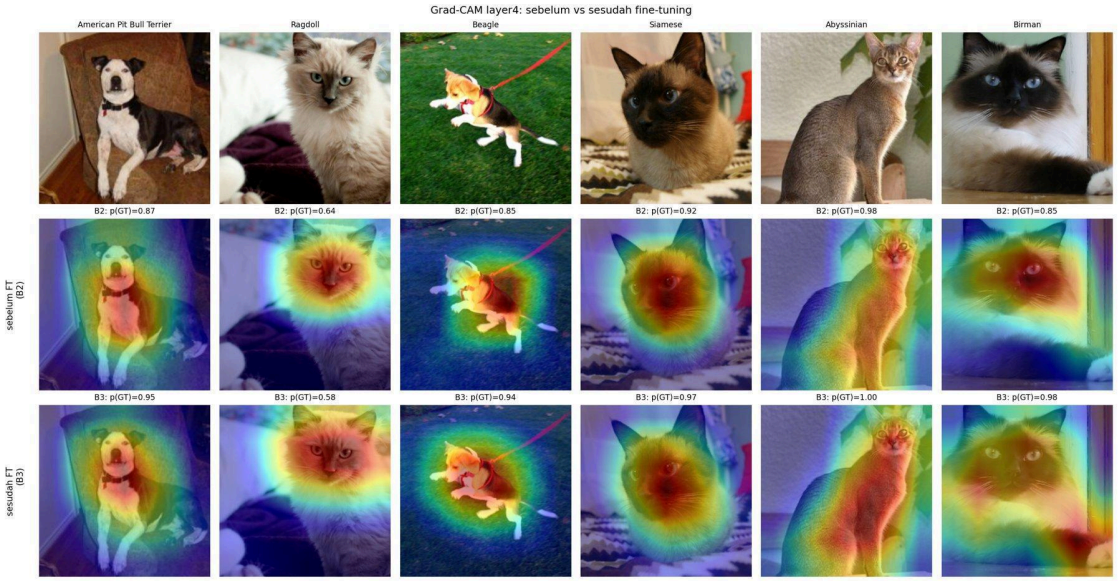
Dari 21 kesalahan, 14 terjadi pada tiga pasangan ras yang mirip: Birman–Ragdoll, Pit Bull–Staffordshire, dan Basset–Beagle. Confidence yang sangat tinggi pada beberapa kesalahan (0,95–0,97) menunjukkan model yakin pada ciri yang salah ketika ciri pembeda utama tidak terlihat di foto.

C4. Rekomendasi Rekayasa dan Batasan Eksperimen

Rekomendasi. Untuk data terbatas, strategi terbaik adalah transfer learning dengan fine-tuning parsial. Untuk server, EfficientNet-B0 paling disarankan (F1 0,929, hanya 1,1 juta parameter dilatih). Untuk HP, MobileNetV3-Small lebih cocok karena sekitar 3× lebih cepat (0,34 ms per gambar) dengan F1 0,896. Jika data sangat sedikit atau GPU terbatas, mulai dari feature extraction (Slide 29). Augmentasi tetap disarankan karena menekan overfitting (gap 0,107 → 0,048). Untuk ras yang sering tertukar, perlu ditambah data yang menampilkan ciri pembedanya.

Batasan. (1) Hanya satu seed, sehingga selisih di bawah 1% belum signifikan. (2) Hanya 10 dari 37 kelas. (3) Satu set hyperparameter tanpa tuning. (4) B1 berhenti saat train loss masih turun. (5) Latensi diukur di GPU T4, bukan di HP. (6) Val set dipakai untuk early stopping sekaligus pemilihan model.

C5. Grad-CAM layer4: Sebelum vs Sesudah Fine-Tuning



Gambar 4. Grad-CAM layer4: B2/sebelum fine-tuning (baris tengah) vs B3/sesudah fine-tuning (baris bawah)

Gambar 4 membandingkan Grad-CAM layer4 pada model B2 (bobot layer4 masih ImageNet) dan B3 (layer4 sudah di-fine-tune), dengan target kelas aktual. Pada kedua model, fokus aktivasi berada di tubuh hewan, bukan di latar belakang. Perubahan paling mencolok terlihat pada Birman: setelah fine-tuning, fokus bergeser dari wajah ke arah kaki dan badan bawah, yaitu letak ciri "sarung tangan putih" pembeda Birman, dan confidence naik dari 0,85 menjadi 0,98. Secara umum, confidence naik pada 5 dari 6 citra. Ragdoll justru turun (0,64 → 0,58), konsisten dengan temuan C3 bahwa Ragdoll dan Birman sering tertukar. Hal ini menunjukkan fine-tuning membuat layer4 beradaptasi dengan ciri spesifik ras, tidak hanya memakai ciri umum ImageNet (Slide 29). Namun analisis ini bersifat kualitatif dan hanya mencakup 6 citra, sehingga belum dapat digeneralisasi.

Referensi

1. Ioffe, S., & Szegedy, C. (2015). Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. ICML.
2. He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. CVPR.
3. Yosinski, J., Clune, J., Bengio, Y., & Lipson, H. (2014). How transferable are features in deep neural networks? NeurIPS.
4. Howard, J., & Ruder, S. (2018). Universal Language Model Fine-tuning for Text Classification. ACL.
5. Li, X., Chen, S., Hu, X., & Yang, J. (2019). Understanding the Disharmony between Dropout and Batch Normalization by Variance Shift. CVPR.
6. Kirkpatrick, J., et al. (2017). Overcoming catastrophic forgetting in neural networks. PNAS.
7. Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on Image Data Augmentation for Deep Learning. Journal of Big Data.
8. Tan, M., & Le, Q. (2019). EfficientNet: Rethinking Model Scaling for CNNs. ICML. · Howard, A., et al. (2019). Searching for MobileNetV3. ICCV.
9. Selvaraju, R. R., et al. (2017). Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. ICCV.
10. Materi Sesi 05 — Advanced CNNs and Transfer Learning; dokumentasi PyTorch/torchvision.

Pernyataan Penggunaan AI

- **Alat:** Claude (Anthropic).
- **Ruang lingkup:** membantu menyusun kerangka kode notebook; menjelaskan konsep materi; mengecek dan merapikan bahasa jawaban Bagian A dan bagian C yang saya tulis;
  Verifikasi: saya membaca dan memahami setiap sel kode, memastikan trainable params B2 = 5.130 sesuai petunjuk soal, memastikan split data tidak beririsan, mencocokkan semua angka laporan dengan summary.csv, dan memeriksa konsep terhadap slide Sesi 05.